



**Instituto
Europeo
de Posgrado**

Sistema de validación de datos mediante OCR y procesamiento de lenguaje natural (IA) en la Universidad UTE

Trabajo fin de estudio presentado por:	David Ovidio Rubio Caballero
Tipo de trabajo:	TFM
Director/a:	Julián Ortega
Fecha:	28/10/2025

Índice

1	Resumen	3
2	Abstract	3
3	Introducción.....	5
3.1	Objetivo General	5
3.2	Objetivos Específicos	5
3.3	Metodología.....	6
3.3.1	Identificación y Análisis del Problema	6
3.3.2	Planificación de la Solución	6
4	Identificación y descripción un problema al interior de la organización	8
4.1.1	Descripción de la empresa a intervenir	8
4.1.2	Misión	8
4.1.3	Visión	8
4.1.4	Mapa de procesos.....	9
4.1.5	Descripción del proceso a intervenir	10
4.1.6	Descripción del problema que presenta el proceso	10
5	Establecimiento de planes de acción para la solución del problema	11
5.1	Establecimiento de objetivos	11
5.2	Descripción de la solución.....	12
5.3	Secuencia de actividades para ejecución de la solución	12
5.4	Descripción de recursos necesarios para la ejecución de la solución	13
6	Definición del alcance de la solución, partes interesadas, cronograma y presupuestos	15
6.1	Alcance final de la solución	15
6.1.1	Alcance funcional.....	15
6.1.2	Alcance técnico.....	15
6.1.3	Limitaciones técnicas esperadas	16
6.2	Identificación de responsables de las actividades para ejecución	17
6.3	Cronograma de ejecución	17
6.4	Presupuesto	19
7	Referencias bibliográficas	20

1 Resumen

La Universidad UTE enfrenta desafíos operativos significativos en sus procesos de registro académico debido a las inconsistencias en los datos de los estudiantes. Estos problemas se originan en el ingreso manual de información, generando errores que impactan la emisión de certificados, carnés estudiantiles y la precisión de los reportes a entidades regulatorias.

Este proyecto presenta la implementación de una solución de software basada en Inteligencia Artificial para automatizar la validación de documentos. El sistema emplea un pipeline de IA de doble etapa: primero, un motor de Reconocimiento Óptico de Caracteres (OCR) basado en aprendizaje profundo (EasyOCR) que extrae el texto en bruto directamente de imágenes complejas, demostrando alta robustez ante el ruido y los fondos de los documentos. Segundo, un Modelo de Lenguaje Grande (LLM) interpreta este texto para su correcta extracción y estructuración.

Esta solución contrasta automáticamente la información extraída de los documentos de identidad con la base de datos existente, identificando discrepancias y asegurando la integridad de los registros históricos. Se espera que este sistema reduzca drásticamente los errores manuales, agilice los trámites administrativos y garantice el cumplimiento normativo.

Palabras clave: Reconocimiento Óptico de Caracteres (OCR), Inteligencia Artificial (IA), Validación de Datos, Registros Académicos, Automatización de Procesos, Procesamiento de Imágenes, Integridad de Datos

2 Abstract

UTE University faces significant operational challenges in its academic registration processes due to data inconsistencies. These problems stem from manual data entry, leading to errors that impact the issuance of certificates, student IDs, and the accuracy of reports submitted to regulatory bodies.

This project presents the implementation of an AI-based software solution to automate document validation. The system employs a dual-stage AI pipeline: first, a deep-learning-based Optical Character Recognition (OCR) engine (EasyOCR) extracts raw text directly from complex images, demonstrating high robustness against document noise and backgrounds. Second, a Large Language Model (LLM) interprets this text for its correct extraction and structuring.

This solution automatically cross-references the information extracted from identity documents against the existing database, identifying discrepancies and ensuring the integrity of historical records. This system is expected to drastically reduce manual errors, streamline administrative procedures, and ensure regulatory compliance.

Keywords: Optical Character Recognition (OCR), Artificial Intelligence (AI), Data Validation, Academic Records, Process Automation, Image Processing, Data Integrity

3 Introducción

El registro y la gestión de la identidad del estudiante son procesos fundamentales en cualquier institución de educación superior (Babi, 2018). La Universidad UTE, en su esfuerzo por mantener registros históricos precisos, se enfrenta a una problemática recurrente: los errores derivados del ingreso manual de datos. Esta situación genera un "cuello de botella" administrativo, retrasando procesos críticos para el estudiante y comprometiendo la calidad de la información entregada a las entidades de control del estado.

La digitalización de documentos, si bien es un primer paso, no soluciona el problema de la validación. Los documentos escaneados (como cédulas de identidad en formato PDF) a menudo se almacenan sin una verificación automática de su contenido. Este proyecto aborda dicha brecha mediante la aplicación de técnicas de Inteligencia Artificial para crear un sistema de validación automático, robusto y escalable.

3.1 Objetivo General

Implementar un sistema de Reconocimiento Óptico de Caracteres (OCR) basado en Inteligencia Artificial para automatizar la extracción, validación y corrección de datos de estudiantes a partir de sus documentos de identidad escaneados, con el fin de asegurar la integridad de los registros académicos de la Universidad UTE.

3.2 Objetivos Específicos

Para cumplir con el objetivo general, se establecieron tres objetivos específicos:

1. Analizar y comparar diferentes algoritmos de pre-procesamiento de imágenes (Visión por Computadora) (Sauvola & Pietikäinen, 2000) para optimizar la calidad del texto extraído de DNI escaneados con ruido e iluminación variable.
2. Implementar un pipeline de OCR (EasyOCR) robusto que consuma las imágenes de alta resolución y genere una extracción de texto en bruto.
3. Integrar un Modelo de Lenguaje Grande (LLM como Gemini) para interpretar el texto en bruto del OCR y estructurarlo en campos de datos definidos (Nombre, Apellido, Cédula, etc.).
4. Desarrollar un módulo de comparación que valide los datos extraídos por la IA contra la base de datos de registros estudiantiles existente.

5. Generar un reporte de discrepancias (matriz de bits de coincidencia) que sirva como herramienta para la corrección administrativa de los registros erróneos.

3.3 Metodología

La metodología seleccionada es el Prototipado Evolutivo. Dada la naturaleza experimental de la optimización del OCR, este enfoque permite construir, probar y refinar iterativamente los componentes del sistema. Iniciaremos con un prototipo básico y lo mejoraremos de forma incremental.

3.3.1 Identificación y Análisis del Problema

El problema central es la falta de integridad de los datos en el sistema de registro estudiantil. El análisis demuestra que existen discrepancias entre los datos ingresados manualmente y los datos reales en los documentos de identidad. Esto se debe a errores de tipeo, omisión de nombres o inversión de apellidos durante el ingreso manual.

3.3.2 Planificación de la Solución

La solución se planifica en cuatro fases principales:

Fase 1: Laboratorio de OCR: Probar y seleccionar el mejor pipeline de pre-procesamiento de imágenes (OpenCV) y técnicas de conversión, como la binarización adaptativa (Sauvola & Pietikäinen, 2000), para maximizar la precisión de EasyOCR (Jaided AI, 2020) en los documentos reales de la UTE.

Fase 2: Desarrollo del Extractor (IA): Construir y refinar los prompts para el LLM (Gemini) que aseguren una extracción de datos precisa y en el formato JSON requerido.

Fase 3: Desarrollo del Validador: Crear el script que ejecute el bucle completo de OCR-Extracción y compare los resultados con una base de datos de Excel, generando los bits de validación.

Fase 4: Despliegue y Pruebas: Implementar el script en un entorno de Colab/Servidor para procesar el lote completo de múltiples estudiantes y analizar los resultados consolidados.

3.3.2.1 Definición de Alcance y Recursos

El alcance de este prototipo funcional se define de la siguiente manera:

- El desarrollo de un script de procesamiento por lotes en un entorno de google colab utilizando el lenguaje Python.

- El análisis y optimización del pre-procesamiento de imágenes sobre el conjunto de datos de muestra
- El uso del motor de EasyOCR para la extracción de texto en bruto.
- La integración con una API de un Modelo de Lenguaje Grande para la extracción estructurada de información.
- El procesamiento del conjunto de datos de prueba completo proporcionado por la universidad.
- La generación de un archivo Excel final que contenga la comparación entre los datos de la base de datos y los datos extraídos por la IA.
- El objetivo final es la creación de un prototipo funcional que pruebe la viabilidad técnica y la precisión del método propuesto.

Excluido del Alcance:

- El desarrollo de una interfaz gráfica de usuario (GUI) para el consumo del sistema.
- La integración directa o en tiempo real con las bases de datos de producción de la UTE. El prototipo consume y genera archivos planos.
- La corrección automática de los datos en la base de datos de origen. El sistema solo reportará las discrepancias.
- El entrenamiento de un modelo de OCR propio. Se utilizarán herramientas pre-entrenadas.
- El escalado del prototipo para procesar miles de documentos simultáneamente, aunque el diseño permitirá su escalabilidad futura.

Recursos Necesarios

Para la ejecución del proyecto se han identificado los siguientes recursos:

Recursos Tecnológicos:

- Entorno de Desarrollo: Google Colab.
- Lenguaje: Python 3.x.
- Motor OCR: EasyOCR
- Plataforma de IA: Acceso a la API de Google AI Studio, utilizando el modelo gemini-2.5-flash.

Recursos de Datos:

- Base de Datos de Prueba: el archivo conteniendo los registros de los estudiantes.

- **Cuerpo de Documentos:** los archivos PDF de DNI escaneados, asociados a los registros del Excel.

Recursos Humanos:

- **Investigador (estudiante):** responsable del desarrollo, ejecución de pruebas, análisis de algoritmos y documentación del proyecto.
- **Director (tutor):** encargado de la supervisión metodológica y validación de la arquitectura de la solución.

4 Identificación y descripción un problema al interior de la organización

4.1.1 Descripción de la empresa a intervenir

La Universidad UTE, una institución de educación superior privada, con personería jurídica, autonomía académica, administrativa, financiera y orgánica. Su sede principal está ubicada en la ciudad de Quito, Ecuador.

Como una de las principales universidades del país, la UTE gestiona una población estudiantil considerable, distribuida en múltiples facultades y carreras de grado y posgrado. Esta operación implica la administración de un volumen masivo y creciente de registros históricos y datos sensibles de estudiantes.

4.1.2 Misión

La Universidad UTE es una institución de educación superior particular ecuatoriana, conformada por una comunidad académica humanista e innovadora, generadora de saberes mediante la investigación como base para la formación integral de ciudadanos, capaces de ejercer una profesión y vincularse a la realidad del país para mejorarla (Universidad UTE, s.f.).

4.1.3 Visión

Ser una universidad líder en el ámbito nacional en la formación innovadora y con altos estándares de calidad, de profesionales actores del mejoramiento social (Universidad UTE, s.f.).

4.1.4 Mapa de procesos

El flujo general de datos del estudiante en la universidad (visible en **Figura 1**) sigue esta secuencia:

- Admisión: El postulante ingresa sus datos personales básicos en un formulario web.
- Carga de Documentos: El estudiante sube sus documentos habilitantes (cédula, título de bachiller) en formato digital (usualmente PDF escaneado).
- Registro Manual: El propio estudiante, transcribe la información de los documentos escaneados a los campos formales del sistema académico.
- Validación (El Problema): Este paso es actualmente manual, propenso a errores, o inexistente.
- Generación de Matrícula: Se oficializa la matrícula del estudiante.
- Consumo de Datos: Otros departamentos (Financiero, Bienestar Estudiantil, Emisión de Certificados) consumen los datos ingresados en el paso 3.

Flujo General de Datos del Estudiante (Mapa de Proceso)




Figura 1. Flujo de datos

4.1.5 Descripción del proceso a intervenir

El proceso a intervenir es el Paso 3 (Registro Manual) y el Paso 4 (Validación). Actualmente, el estudiante ingresa al sistema de admisiones y digita manualmente sus datos personales, una vez digitados, sube los documentos correspondientes al título de bachiller y cédula de identidad.

El sistema actual confía plenamente en que la digitación del estudiante es correcta. No existe un mecanismo automático que "lea" el PDF y lo compare con lo digitado.

4.1.6 Descripción del problema que presenta el proceso

Errores de Datos y Retrasos al Estudiante: Es común que los datos ingresados manualmente no coincidan con los datos reales. Un estudiante llamado "JOSSUE DANIEL" puede ser registrado como "JOSUE", o "VALLADARES VALENZUELA" como "VALLADARES". Estos errores, aunque pequeños, impiden la generación automática de certificados oficiales y carnés estudiantiles, forzando al estudiante a un trámite burocrático de corrección de datos.

Ineficiencia Administrativa: El personal administrativo debe dedicar tiempo valioso a la tarea repetitiva de digitación y, posteriormente, a la corrección de los errores reportados por los estudiantes, en lugar de tareas de mayor valor.

Incumplimiento Regulatorio: La Universidad UTE, como todas las IES, debe presentar reportes periódicos a entidades de control del estado (como el CACES y el SENESCYT). Estos reportes exigen una consistencia absoluta entre el número de cédula, nombres y apellidos del estudiante. Las discrepancias generadas por la digitación manual exponen a la universidad a sanciones y a la invalidación de sus reportes.

5 Establecimiento de planes de acción para la solución del problema

Con la meta de abordar la falta de integridad de datos en los registros académicos de la Universidad UTE, se diseñó un plan de acción centrado en el desarrollo de un prototipo funcional que automatiza la validación de documentos mediante un pipeline con diversas herramientas de IA. Este plan que se plantea sigue la metodología de Prototipado Evolutivo, la cual está basada en el desarrollo incremental, las pruebas continuas y la mejora iterativa del sistema. A continuación, se detallan los objetivos, la descripción técnica de la solución, la secuencia de actividades y los recursos necesarios para su implementación.

5.1 Establecimiento de objetivos

En este apartado se definen los objetivos generales y específicos que guiaron la solución propuesta. Todos ellos se basaron en la necesidad de garantizar confiabilidad, consistencia y trazabilidad en los registros académicos de los alumnos.

Como objetivo general, se estableció la implementación de un sistema de Reconocimiento Óptico de Caracteres (OCR) basado en Inteligencia Artificial para automatizar la extracción, la validación y la corrección de datos de los documentos de identidad escaneados y en formato PDF.

Como objetivos específicos se detectaron los siguientes:

1. Automatizar la validación de datos: desarrollar un script en Python capaz de procesar por lotes o batches una base de datos de estudiantes (en formato Excel) y sus documentos PDF asociados.
2. Extraer datos de imágenes: implementar un motor OCR que sea robusto y capaz de gestionar la variabilidad en la calidad de los documentos escaneados, considerando factores como ruido e iluminación.
3. Implementar un pipeline robusto: integrar EasyOCR para optimizar la conversión de PDF a imagen de alta resolución, garantizando así una mayor precisión en la percepción de la información.
4. Estructurar datos con IA: utilizar un Modelo de Lenguaje (LLM) como Gemini para interpretar el texto en bruto proveniente del OCR y estructurarlo en campos JSON predefinidos (Cédula, Nombres, Apellidos, etc.).
5. Cuantificar la precisión del modelo: diseñar un módulo de validación donde se comparen programáticamente los datos extraídos por la IA con los datos existentes.

6. Generar reportes finales: producir un informe comparativo en formato de tabla (*df_comparacion*) y una matriz de coincidencia para mostrar el nivel de éxito del sistema, facilitando así el trabajo de corrección del personal administrativo.

5.2 Descripción de la solución

La solución propuesta consiste en un sistema de software basado en IA y diseñado para automatizar y validar los datos de los documentos de identidad de los estudiantes. Con este sistema se aborda la falta de validación automática que fue destacada en el Paso 4.

Este sistema se implementa con un pipeline de doble etapa desarrollado en un entorno de Google Colab que aprovecha las herramientas de Deep Learning y los modelos de lenguaje para superar los desafíos ofrecidos por los documentos escaneados como el ruido o la baja resolución (en esta labor, los motores de OCR tradicionales como Tesseract (Smith, 2007) demostraron ser ineficaces), y se estructura en las siguientes etapas:

Etapas	Herramienta	Descripción	Objetivo
Etapas de percepción (El “Ojo”)	EasyOCR, motor basado en aprendizaje profundo.	Lee imágenes de alta resolución (generadas con PyMuPDF a zoom 5.0) e ignora eficazmente el ruido de fondo, extrayendo el texto en bruto (texto_para_gemini).	Capturar con precisión el texto de los documentos escaneados.
Etapas de comprensión (El “Cerebro”)	Google Gemini (Gemini Team, 2023) (modelo Gemini-2.5-flash).	El texto en bruto de EasyOCR se envía a la API de Gemini con un prompt especificado. Después, el LLM interpreta el texto, comprende el contexto y estructura la información relevante en un JSON.	Transformar el texto desordenado en datos estructurados, listos para validar.

Este pipeline de doble IA resultante reduce la intervención humana, acelera la gestión administrativa y fortalece el cumplimiento normativo.

5.3 Secuencia de actividades para ejecución de la solución

En el prototipo funcional que se ha implementado en el archivo *ORC_v10.ipynb*, se realiza el proceso de validación de datos de forma automatizada siguiendo la siguiente secuencia:

1. Carga y preparación de datos: se carga el archivo *datos_2.xlsx* en un DataFrame de pandas.

2. Conversión de PDF a imagen: cada PDF, localizado en la carpeta *c_dni* y cuyo nombre está en la columna DOCUMENTO, es transformado en una imagen PNG de alta resolución (zoom 5.0) con PyMuPDF y guardado dentro de *imagen_pdf*.
3. Duplicación estructural: se genera una copia del DataFrame (*df_analisis*) con nuevas columnas vacías para almacenar los datos extraídos por la IA.
4. Bucle de OCR y extracción (loop principal): en este loop se inicializan los modelos EasyOCR y Gemini, se procesa individualmente cada registro, se extrae el texto crudo con OCR, se envía el texto a Gemini (que devuelve los datos en formato JSON) y se analiza la respuesta para llenar automáticamente las columnas correspondientes.
5. Limpieza y estandarización: se normalizan formatos como fechas, mayúsculas o espacios para conseguir una comparación más uniforme.
6. Análisis de comparación: se crea *df_comparacion* para contrastar evaluando las coincidencias de los datos originales con los de la IA y genera las columnas *_BIT* (1 para éxito y 0 para fallo).
7. Visualización de resultados: se usa Matplotlib para generar y mostrar gráficos de barras que muestren los niveles de éxito alcanzados en cada campo comparado, facilitando así la interpretación de los resultados.

5.4 Descripción de recursos necesarios para la ejecución de la solución

Este prototipo se construyó utilizando recursos accesibles y de bajo costo, demostrando la viabilidad de la solución.

Categoría	Recursos específicos	Fuentes/Descripción
Recursos tecnológicos (plataforma)	-Entorno de desarrollo: Google Colab. -Lenguaje: Python 3.x. (Van Rossum & Drake, 2009).	-Google Colab: Plataforma en la nube que permite la ejecución colaborativa y escalable de código. -Python 3.x: Lenguaje de programación usado por su compatibilidad con bibliotecas de Inteligencia Artificial y procesamiento de datos.
Recursos de software (bibliotecas)	Pandas (McKinney, 2010), numpy, PyMuPDF (fitz), opencv-python-headless requests.	Herramientas para procesamiento de datos, manejo de imágenes y conexión con APIs.
Recursos de IA	EasyOCR (percepción visual), Google Gemini (gemini-2.5-flash) (comprensión semántica).	Modelos de IA usados para reconocimiento de texto y estructuración inteligente.
Recursos de datos	Archivo de prueba <i>datos_2.xlsx</i> (12 registros) y 12 archivos PDF de DNI escaneados almacenados en la carpeta <i>c_dni</i> .	Datos empleados para la validación del prototipo funcional.
Recursos humanos	Investigador (desarrollo, pruebas y documentación) y Director (supervisión y validación metodológica).	Roles clave para garantizar el rigor técnico y académico del proyecto.

6 Definición del alcance de la solución, partes interesadas, cronograma y presupuestos

Habiendo validado la viabilidad técnica del pipeline de IA de doble etapa (EasyOCR + Gemini) a través del prototipo funcional (ORC_v10.ipynb), esta sección define el plan de acción para evolucionar dicho prototipo.

El objetivo principal es escalarlo de una prueba de concepto (12 registros) a una solución robusta capaz de procesar ("barrer") la totalidad de la base de datos de registros estudiantiles de la Universidad UTE.

6.1 Alcance final de la solución

El alcance de esta solución final es evolucionar el prototipo de Google Colab a un script de procesamiento masivo capaz de analizar la base de datos histórica completa de estudiantes de la UTE.

El alcance del prototipo incluye:

La ingesta de la base de datos "maestra" completa (potencialmente miles de registros) desde un archivo Excel o CSV.

6.1.1 Alcance funcional

En este apartado se detallan las funciones, capacidades y comportamientos que la solución final será capaz de realizar desde el punto de vista del usuario o del proceso institucional:

- Automatizar la lectura masiva de registros de estudiantes desde un Excel o CSV.
- Procesar en lote todos los PDFs con los documentos de identidad de los estudiantes.
- Extraer texto con OCR y estructurarlo automáticamente con la ayuda de un LLM (Gemini).
- Comparar los datos extraídos con la base de datos institucional.
- Generar reportes de fallos (*df_comparacion*) y gráficos de coincidencia.
- Registrar errores, archivos que causen problemas y causas de fallo.
- Permitir que el proceso sea supervisado por un operador humano.

6.1.2 Alcance técnico

En este apartado se describen las herramientas y tecnologías necesarias para completar las funciones del apartado anterior:

- Implementación en Python 3.x ejecutado en Google Colab.
- Uso de PyMuPDF para la conversión de documentos PDFs a imágenes PNG de alta resolución (zoom 5.0).
- Utilización de EasyOCR como motor principal de Reconocimiento Óptico de Caracteres (OCR).
- Envío del texto extraído a un LLM (Gemini 2.5 Flash) para su interpretación y estructuración semántica en formato JSON.
- Uso de la biblioteca pandas para procesamiento de los datos masivos.
- Creación de un *pipeline batch* capaz de procesar todos los documentos escaneados, incluyendo el manejo de errores y reintentos.
- Registro (*logging*) de eventos y errores, que permite auditar qué archivos fallaron y las causas asociadas.
- Ejecución del loop principal de procesamiento (PDF → PyMuPDF → EasyOCR → Gemini → JSON) sobre la totalidad de la carpeta de documentos escaneados.
- Generación de un único *df_comparacion* final que contenga la matriz de bits (1 o 0) de todos los estudiantes procesados.

Excluido del Alcance:

Para mantener el enfoque en un prototipo funcional que pruebe la metodología, se excluye lo siguiente:

- El desarrollo de una interfaz gráfica de usuario (GUI).
- La integración directa o en tiempo real con las bases de datos de producción; la solución final seguirá consumiendo y generando archivos planos.
- La corrección automática de los datos en la base de datos de origen; la solución solo reportará las discrepancias para la acción administrativa.

6.1.3 Limitaciones técnicas esperadas

Vemos necesario detallar también las posibles limitaciones que pueden surgir y que son condiciones relevantes para la operación del sistema final:

- Dependencia de la calidad del PDF: las imágenes con muy baja resolución, ruido o mala iluminación pueden afectar negativamente y degradar la precisión de EasyOCR y del LLM.
- Limitaciones de la API de Gemini:
 - El tiempo total de procesamiento dependerá de la velocidad de respuesta de la API.
 - Puede haber limitaciones por cuotas diarias o mensuales según el plan contratado.
 - La latencia que se vaya acumulando puede incrementar el tiempo de ejecución.

- Uso intensivo de almacenamiento:
 - Las imágenes PNG de alta resolución generadas a partir de los PDFs pueden ocupar demasiado espacio.
 - Debido al volumen total de los documentos, puede ser necesario hacer una limpieza periódica o contratar más espacio.
- Limitación de velocidad por secuencia: aunque Python puede procesar miles de registros, el pipeline completo es computacionalmente costoso.
- Dependencia de la conexión a internet: al introducir la etapa de LLM, el proceso tiene una dependencia externa de comunicación estable con la API de Gemini.

6.2 Identificación de responsables de las actividades para ejecución

El éxito del proyecto de escalado depende de los mismos roles clave del prototipo, pero con responsabilidades enfocadas en la producción:

- Investigador (Líder Técnico): Responsable de refactorizar el script de Python (ORC_v10.ipynb) para el procesamiento masivo, gestionar la ejecución del loop completo, optimizar las llamadas a la API y analizar los resultados finales.
- Director (Supervisor del Proyecto): Encargado de la supervisión metodológica y la validación de los resultados consolidados.
- Universidad UTE (Cliente/Interesado): Responsable de proveer el acceso a la base de datos completa (Excel/CSV) y al repositorio total de documentos PDF escaneados.

6.3 Cronograma de ejecución

El cronograma se basa en la metodología de prototipo evolutivo.

La Fase 1 (Prototipo) ya está completa (como se puede ver en el archivo adjunto a la entrega junto a este documento). En la siguiente tabla se muestra el histórico del plan completo de evolución de ese prototipo a una solución de producción.

Tabla 1
Cronograma de actividades

Fase	Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6	Mes 7	Mes 8	Mes 9
1	Validación (Prototipo) (Análisis de EasyOCR vs. Tesseract y desarrollo de ORC_v10.ipynb en 12 registros)	X	X							
2	Fase Piloto (Escalado 1K) (Optimizar script para 1,000 registros, añadir logs y manejo de errores)			X	X					
3	Fase de Procesamiento Masivo (Ejecución del script para "barrer" la base de datos histórica completa, ej. 50,000+ registros)					X	X	X		
4	Análisis de Discrepancias (Análisis del <i>df_comparacion</i> final y generación de reportes de errores)								X	
5	Entrega y Cierre (Entrega del reporte final de discrepancias y documentación técnica)									X

6.4 Presupuesto

Una de las ventajas clave de la solución propuesta es su alta viabilidad económica. El desarrollo del prototipo funcional (ORC_v10.ipynb) se completó con un costo de \$0.00, ya que utilizó exclusivamente herramientas de código abierto (Python, EasyOCR, PyMuPDF) y los niveles de gratuidad de servicios en la nube (Google Colab y Google AI Studio).

El presupuesto para la evolución del prototipo a una solución de producción (Fases 2-5 del cronograma, para procesar la base de datos completa) mantiene esta eficiencia, incurriendo únicamente en costos operativos mínimos de servicios de nube.

El siguiente presupuesto se basa en una estimación de 50,000 registros históricos a procesar.

Tabla 2
Presupuesto

Rubro	Descripción	Justificación	Valor (USD)
Recursos Humanos	Investigador / Director	Recursos académicos (TFM)	\$0.00
Plataforma (Software)	Google Colab (Pro)	Necesario para evitar <i>timeouts</i> en el procesamiento masivo de 50,000 registros. (Aprox. \$10/mes durante 5 meses)	\$50.00
Servicios de IA (API)	Google Gemini (gemini-2.5-flash)	Costo de API para la "Etapa de Comprensión". (Estimación: 50,000 registros a ~\$0.00046 por registro)	\$22.75
Servicios de IA (OCR)	EasyOCR	Herramienta de código abierto, se ejecuta localmente en la GPU de Colab.	\$0.00
Total Estimado (Evolución)			\$72.75

7 Referencias bibliográficas

- Babi, E. (2018).** The role of information systems in managing student academic records in higher education institutions. *International Journal of Education and Development using ICT*, 14(2), 147–160.
- Gemini Team. (2023).** *Gemini: A family of highly capable multimodal models (arXiv:2312.11805)*. arXiv. doi:<https://doi.org/10.48550/arXiv.2312.11805>
- Harris, C. R., & al., e. (2020).** Array programming with NumPy. *Nature*, 585, 357–362. doi:<https://pubmed.ncbi.nlm.nih.gov/32939066/>
- Jaied AI. (2020).** *EasyOCR: Ready-to-use OCR with 80+ supported languages (Version 1.7.2)*. Obtenido de GitHub: <https://github.com/JaiedAI/EasyOCR>
- McKinney, W. (2010).** Data structures for statistical computing in Python. En S. van der Walt, & J. Millman (Edits.), *Proceedings of the 9th Python in Science Conference* (págs. 51–56).
- MuPDF Team. (s.f.).** *PyMuPDF (fitz) [Software]*. Obtenido de High-performance Python library for PDF & document processing: <https://pymupdf.readthedocs.io/>
- OpenCV Development Team. (s.f.).** *OpenCV (Open Source Computer Vision Library) [Software]*. Obtenido de OpenCV: <https://opencv.org/>
- Pressman, R. S. (2010).** *Ingeniería del Software: Un enfoque práctico*. McGraw-Hill. Obtenido de <https://www.dykinson.com/libros/ingenieria-del-software-un-enfoque-practico/9781456287726/>
- Reitz, K. (s.f.).** *Requests: HTTP for Humans [Software]*. Obtenido de Requests: HTTP for Humans: <https://github.com/psf/requests>
- Sauvola, J., & Pietikäinen, M. (2000).** Adaptive document image binarization. *Pattern Recognition*, 33(2), 225–236. doi:[https://doi.org/10.1016/S0031-3203\(99\)00055-2](https://doi.org/10.1016/S0031-3203(99)00055-2)
- Smith, R. (2007).** An overview of the Tesseract OCR engine. En *ICDAR 2007: Proceedings of the Ninth International Conference on Document Analysis and Recognition* (Vol. 2, págs. 629–633). IEEE. Obtenido de <https://ieeexplore.ieee.org/document/4376991>
- Universidad UTE. (s.f.).** *Misión y visión*. Recuperado el 28 de octubre de 2025, de <https://ute.edu.ec/mision-y-vision/>
- Van Rossum, G., & Drake, F. L. (2009).** *Python 3 Reference Manual*. CreateSpace.